



INFORME DE RESULTADOS PROYECTO: "CLASIFICACIÓN DE FALLAS ELECTRICAS"

Tec. Ciencia de datos e Inteligencia Artificial.
Aprendizaje Automático
2 año, 1 cuatrimestre
Nombre: Espindola Matías



Al finalizar el análisis exploratorio de datos y observar los resultados obtenidos de dicho análisis, se procedió a la implementación de técnicas de escalado de variables con "StandardScaler", como así también se llegó a la decisión de la utilizar "PCA (Principal Component Analysis).

Estas decisiones están basadas en las siguientes condiciones observadas:

1. Diferencia de magnitudes en los valores de las variables: Al tratarse de mediciones eléctricas, de voltaje y de tensión, hay diferencias extremas en las escalas de estas variables. Estas diferencias afectan negativamente a ambos modelos seleccionados inicialmente para el desarrollo de este proyecto, por lo cual se le hizo un escalado mediante "StandardScaler".
2. Mitigación de multicolinealidad y reducción de ruido y dimensionalidad: El análisis de correlación de variables confirmó la alta multicolinealidad existente entre distintas variables del dataset. La cantidad final de variables después del EDA, nos indica unas dimensiones que también pueden interferir con diversos modelos de aprendizaje automático, por lo cual aplicamos "PCA (Principal Component Analysis)", estableciendo que las variables seleccionadas deban explicar el 95%. Esto redujo la cantidad de componentes a 9.

El modelo de Regresión Logística demostró ser mejor en cuanto a sus métricas que k-NN, pero también fue necesario hacer ciertos ajustes en sus hiperparámetros para poder obtener dichas métricas.

Métricas

```

--- Exploración del Hiperparámetro C en Regresión Logística ---

C = 0.01 | Accuracy: 0.3128
C = 0.1  | Accuracy: 0.3911
C = 1    | Accuracy: 0.4162
C = 10   | Accuracy: 0.4721
C = 100  | Accuracy: 0.4888

-----
Mejor C encontrado en esta exploración: C = 100 (Accuracy: 0.4888)

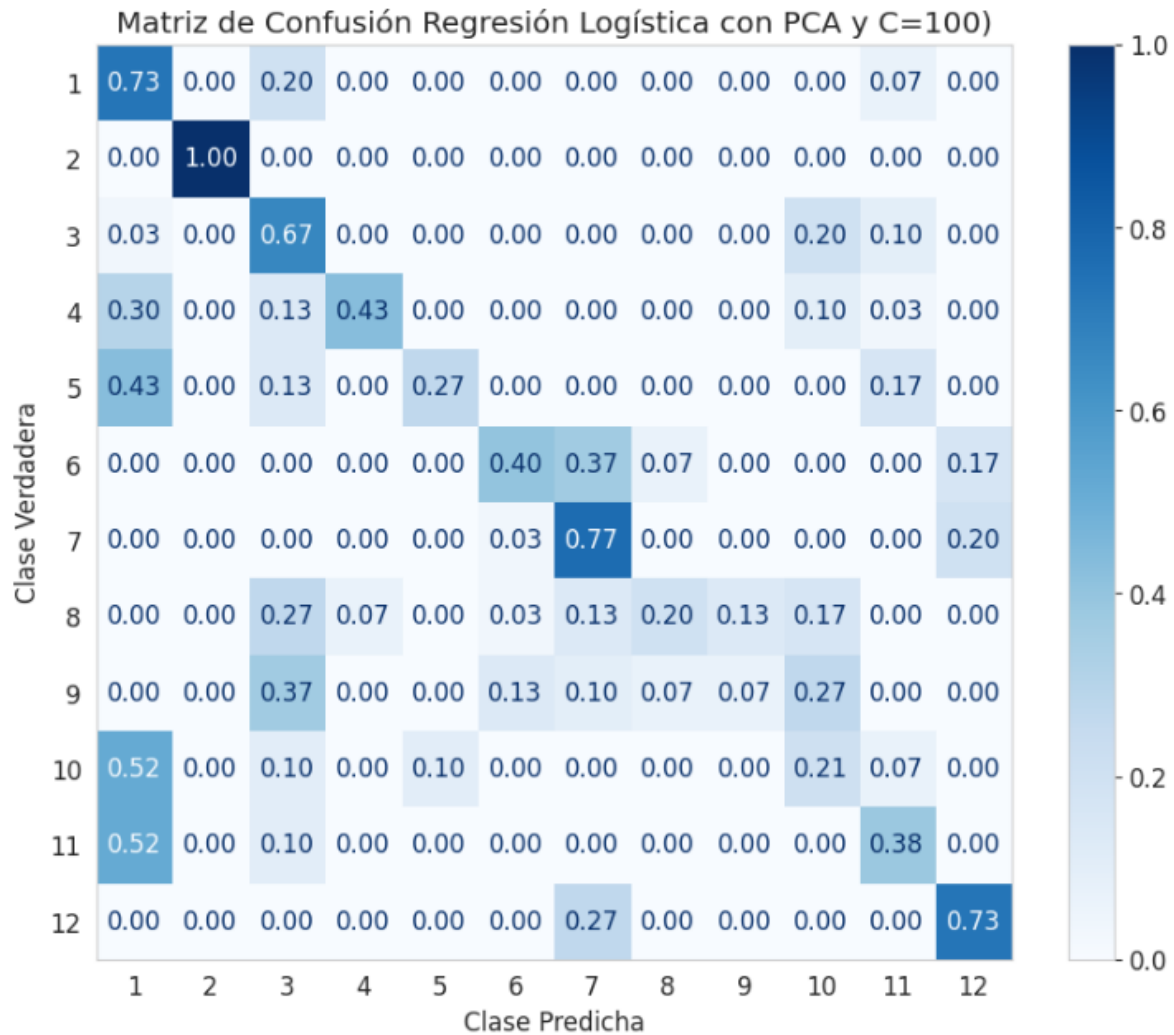
--- Reporte de Clasificación del Modelo Óptimo ---

```

	precision	recall	f1-score	support
1	0.29	0.73	0.42	30
2	1.00	1.00	1.00	30
3	0.34	0.67	0.45	30
4	0.87	0.43	0.58	30
5	0.73	0.27	0.39	30
6	0.67	0.40	0.50	30
7	0.47	0.77	0.58	30
8	0.60	0.20	0.30	30
9	0.33	0.07	0.11	30
10	0.21	0.21	0.21	29
11	0.46	0.38	0.42	29
12	0.67	0.73	0.70	30
accuracy			0.49	358
macro avg	0.55	0.49	0.47	358
weighted avg	0.55	0.49	0.47	358

- El Accuracy global es de 0.4888. El modelo es capaz de predecir correctamente la clase de falla el 48.88% de las veces en datos no vistos. Aunque no es un valor significativamente alto, es el mejor rendimiento que se pudo obtener con los modelos lineales y basados en distancia (k-NN) probados.
- Clase 2: Alcanzo un rendimiento perfecto (100%), esta clase es fácil de distinguir por el modelo, alcanzando 1.00 en precision, recall y f1-score. Esto puede sugerir que las características seleccionadas por el PCA tienen una presencia clara para este tipo de falla.
- Clase con F1-Score alto: Las clases 4, 6, 7 y 12 muestran también un rendimiento aceptable (F1-Score mayor a 0.50).
- Clases débiles con bajo Recall: Las clases 5, 8 y 9 tienen un Recall extremadamente bajo ($C5 = 0.27$, $C8 = 0.20$ y $C9 = 0.07$). Esto puede interpretarse que, si ocurre una falla de Clase 9, el modelo solo la detecta correctamente el 7% de las veces, y el 93% de las veces confunde la falla de Clase 9 con otras clases. Esto es un problema crítico, ya que la falla no se estaría diagnosticando.
- La Macro Average de Precision (0.55) es más alta que la de Recall (0.49), indicando que cuando el modelo decide clasificar una falla, tiene una probabilidad decente de acierto, pero le cuesta identificar todas las ocurrencias de las clases minoritarias o complejas (ej. bajo recall).

Matriz de Confusión



- Eje Y (Filas): Representa la Clase Real de la falla (el valor correcto).
- Eje X (Columnas): Representa la Predicción del Modelo (lo que el modelo dice que es la falla).

Aciertos (Verdaderos Positivos)

Los números grandes y de color más intenso que van desde la esquina superior izquierda hasta la inferior derecha (la diagonal principal) son los Verdaderos Positivos.

- Definición: El modelo predice la Clase X y la clase *realmente* es X
- Interpretación: Muestran cuántas veces el modelo predijo correctamente una falla.
- Ejemplo (Clase 2): Un valor de 30 significa que de 30 fallas reales de Clase 2, el modelo clasificó correctamente 30 como Clase 2 (100% de acierto).

Errores de Confusión (Fuera de la Diagonal)

Los números pequeños fuera de la diagonal son los Errores de Confusión o Diagnósticos Cruzados. Estos son los valores más críticos, ya que indican el riesgo operacional.

Falsos Negativos (Problema de Recall)

- Definición: El evento real es la Clase X, pero el modelo predice *otra clase*.
- Interpretación: Esto es una falla no detectada. Representa la incapacidad del modelo para diagnosticar una falla que *realmente* ocurrió.
- Ejemplo (Fila 9):
 - La fila 9 muestra las 30 fallas reales de clase 9. El verdadero positivo es 2.
 - La suma de todos los otros valores en la Fila 9 (los 28 casos restantes) son **Falsos Negativos** para la clase 9. Es decir, 28 fallas de clase 9 no pudieron ser detectadas y fueron clasificadas erróneamente como otra clase (por ejemplo, Clase 1, Clase 3, etc.).

Falsos Positivos (Problema de Precision)

Los valores en la columna de una clase predicha (excepto la diagonal) son los Falsos positivos para esa clase.

- Definición: El modelo predice la Clase X, pero la clase es realmente *otra clase*.
- Interpretación: Esto es una Falsa Alarma o Mal Diagnostico. Representa las veces que el modelo predijo erróneamente la Clase X, cuando en realidad se trataba de otra falla.
- Ejemplo (Columna 9):
 - La columna 9 muestra todas las veces que el modelo predijo Clase 9 (6 predicciones). El Verdadero Positivo es 2.
 - La suma de todos los otros valores en la Columna 9 (los 4 casos restantes) son **Falsos Positivos** para la Clase 9. Es decir, 4 veces el modelo dijo que la falla era Clase 9, pero en realidad era otra clase (por ejemplo, Clase 5 o Clase 8).

Conclusión sobre el rendimiento

Las métricas se centran en los **Falsos Negativos**. Las clases con una diagonal muy débil (como la Clase 9) tienen un valor elevado de Falsos Negativos. Este es el peor escenario para un diagnóstico, *la falla crítica ocurre, pero el modelo no es capaz de detectarla*.

Conclusiones Finales

El objetivo principal de este proyecto fue desarrollar un modelo de Aprendizaje Automático capaz de clasificar 12 categorías de fallas eléctricas. Luego de comparar los modelos de k-NN y Regresión Logística Multinomial se definió a este último como el modelo de mejor desempeño en base a los resultados obtenidos por sus métricas.

El máximo rendimiento alcanzado por la Regresión Logística fue un Accuracy del 48.88% en el conjunto de prueba, obtenido con una configuración de hiperparámetros óptima ($C=100$) y la aplicación de Análisis de Componentes Principales (PCA).

- Consideración del Balance de Clases

Desde la etapa de Análisis Exploratorio de Datos (EDA), se constató que las 12 clases objetivo estaban razonablemente balanceadas (aproximadamente 30 muestras por clase en el conjunto de prueba). Por lo tanto, el Accuracy se consideró una métrica válida para la selección inicial del modelo, aunque posteriormente se complementó con Precision, Recall y F1-Score para evaluar el rendimiento por clase.

- Análisis Técnico de las Estrategias Implementadas

Estrategia de Preprocesamiento (PCA):

La aplicación de PCA, manteniendo el 95% de la varianza original, fue la técnica crucial. Demostró ser indispensable para mitigar la alta correlación y multicolinealidad inherente en los datos de mediciones eléctricas (corrientes y tensiones) reduciendo la cantidad de variables, o componentes principales para el entrenamiento en 9 variables.

El rendimiento de la Regresión Logística mejoró notablemente sobre el conjunto de datos transformado, lo que confirma que el modelo se benefició de un espacio de características de menor dimensionalidad.

- Optimización de Hiperparámetros:

Se implementó una estrategia de búsqueda con un bucle 'for' para encontrar el valor óptimo de 'C' en la Regresión Logística.

El valor óptimo ($C=100$) indica que el modelo requiere una regularización muy débil ($\text{penalty}='l2'$), sugiriendo que las características ya limpiadas por PCA no están causando un sobreajuste significativo (overfitting).

- Análisis de Desempeño por Clase (Matriz de Confusión):

El bajo valor de Accuracy (**48.88%**) puede explicarse por el desempeño heterogéneo del modelo.

Se observó una capacidad de clasificación perfecta para la Clase 2 (Recall y Precision de 1.00).

El principal punto de falla radica en la reducida capacidad del modelo para detectar las fallas de Clases 5, 8 y 9, particularmente la Clase 9 con un Recall de solo 0.07. Esto significa que el 93% de las ocurrencias de esta falla son clasificadas erróneamente como otras clases (principalmente la Clase 1, como se observa en la Matriz de Confusión), lo que representa un riesgo de falla en su clasificación de diagnóstico crítico.

- Propuestas de Mejora del Modelo

Para alcanzar mejores métricas en un sistema de diagnóstico real, se pueden implementar las siguientes mejoras, centradas en la introducción de no-linealidad:

- 1- Transición a Modelos No Lineales: Explorar algoritmos con mayor capacidad para capturar fronteras de decisión más complejas que separan las fallas más problemáticas (Clases 5, 8, 9).
- 2- Modelos de Conjunto (Ensemble): Implementar Random Forest o Gradient Boosting Machines (GBM), que efectivos y robustos afrontando problemas de alta dimensionalidad.
- 3- Redes Neuronales: Utilizar Redes Neuronales Multicapa (MLP) con una o dos capas ocultas, ya que esta arquitectura puede aprender patrones no lineales de manera efectiva sobre las componentes principales de PCA.
- 4- Estrategias de Muestreo (Sampling Focalizado): Dada la extrema dificultad para identificar las Clases 9, 8 y 5, se podría implementar un sobre muestreo (oversampling) de estas clases específicas en el conjunto de entrenamiento (ej., usando técnicas como SMOTE) para balancear artificialmente la dificultad y mejorar el Recall en esas categorías críticas.